日揮パラレルテクノロジーズ株式会社
2026年10月採用インターンシップ 課題2

DEIに関する
国民の声を集めて
可視化するアルゴリズムを実装せよ



岡田孟史

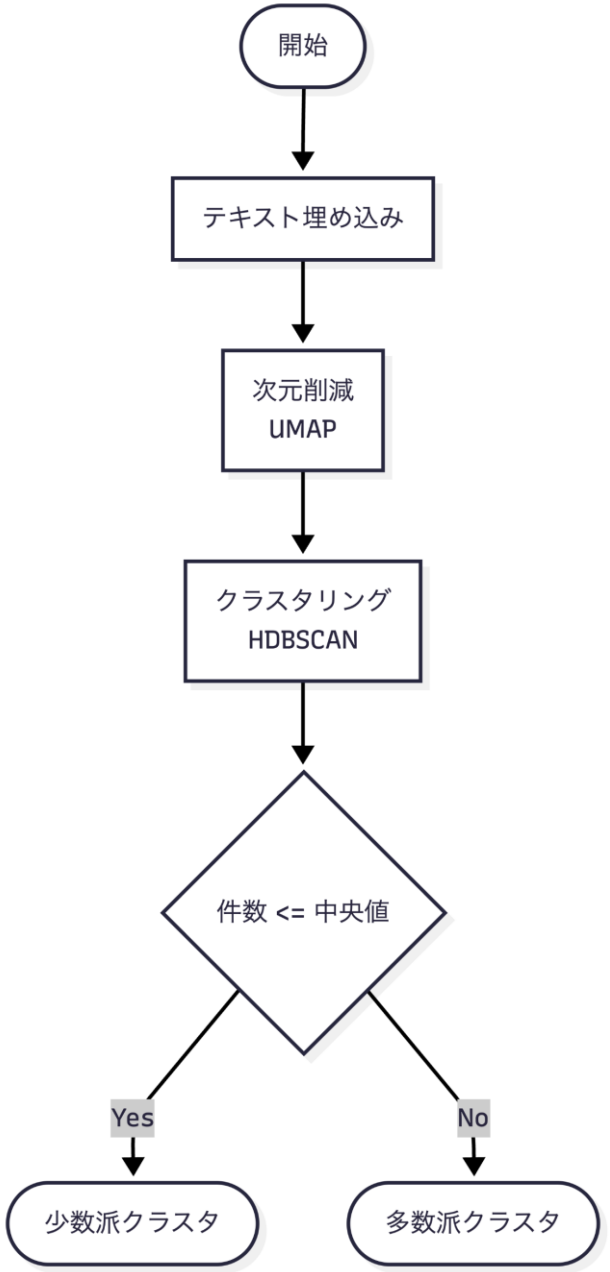
項目

- 選択した手法の説明
- アルゴリズムの設計書
- 選択した取得データの使用方法・取得理由
- 判定結果
- 精度分析
- 精度に関する考察
- 政府/企業への提言
- 工夫点
- 悩んだこと
- Appendix.

選択した手法の説明

データ収集	・国会議事録API(国立国会図書館) ➡国民の代表の発言・無料・構造化済み
前処理	・発言者名除去・空白正規化・長文切り詰め(5,000文字超→冒頭1,000文字)・キーワード除去(公平、包括) ➡DEI文脈外の発言が多数混入するため(EDAで確認)
埋め込み	・multilingual-e5-large-instruct(パラメータ数:560M) ➡動作環境内で最高精度を達成したモデル
次元削減	・UMAP ➡高次元データのクラスタ構造を保持しながら圧縮
クラスタリング	・HDBSCAN ➡少数派を強制分類せず独立グループとして検出
解釈	・XAI(SHAP/LIME) ➡ブラックボックスモデルの判断根拠を可視化
アプリ化	・RAGアプリケーション ➡実際に質問して国会発言を検索・考察できる

アルゴリズムの設計書



埋め込みモデル：multilingual-e5-large-instruct

UMAP：n_components=10,n_neightbors=15

HDBSCAN：min_cluster_size=50

中央値：102件

※疑似言語等を用いて、手書きで設計後、
図解ツール・記法ライブラリMermaidで清書

選定した取得データの使用方法・取得理由

●使用方法

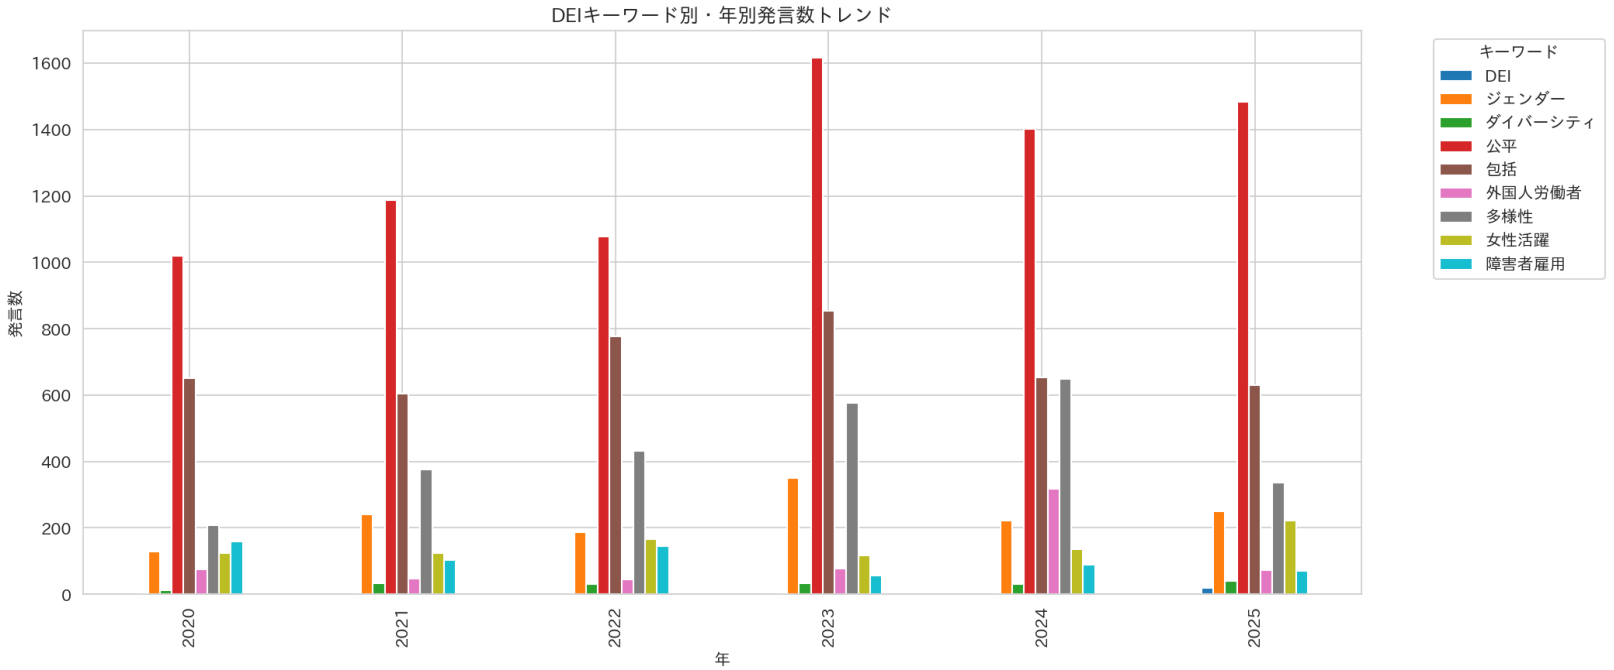
- **キーワード**： DEI、多様性、ダイバーシティ、ジェンダー、女性活躍、外国人労働者、障害者雇用(計7個)
- **取得期間**：2020～2025年(半年ごとに分割取得)
- **取得件数**：18,259件(重複除去後)
- **絞り込み件数**：6,301件(「公平」「包括」を除外)
- **クラスタリング**：発言テキストを埋め込みベクトルに変換し入力データとして使用
- **アプリ連携**：ChromaDBに格納しRAGアプリでの検索

●取得理由

データソース比較

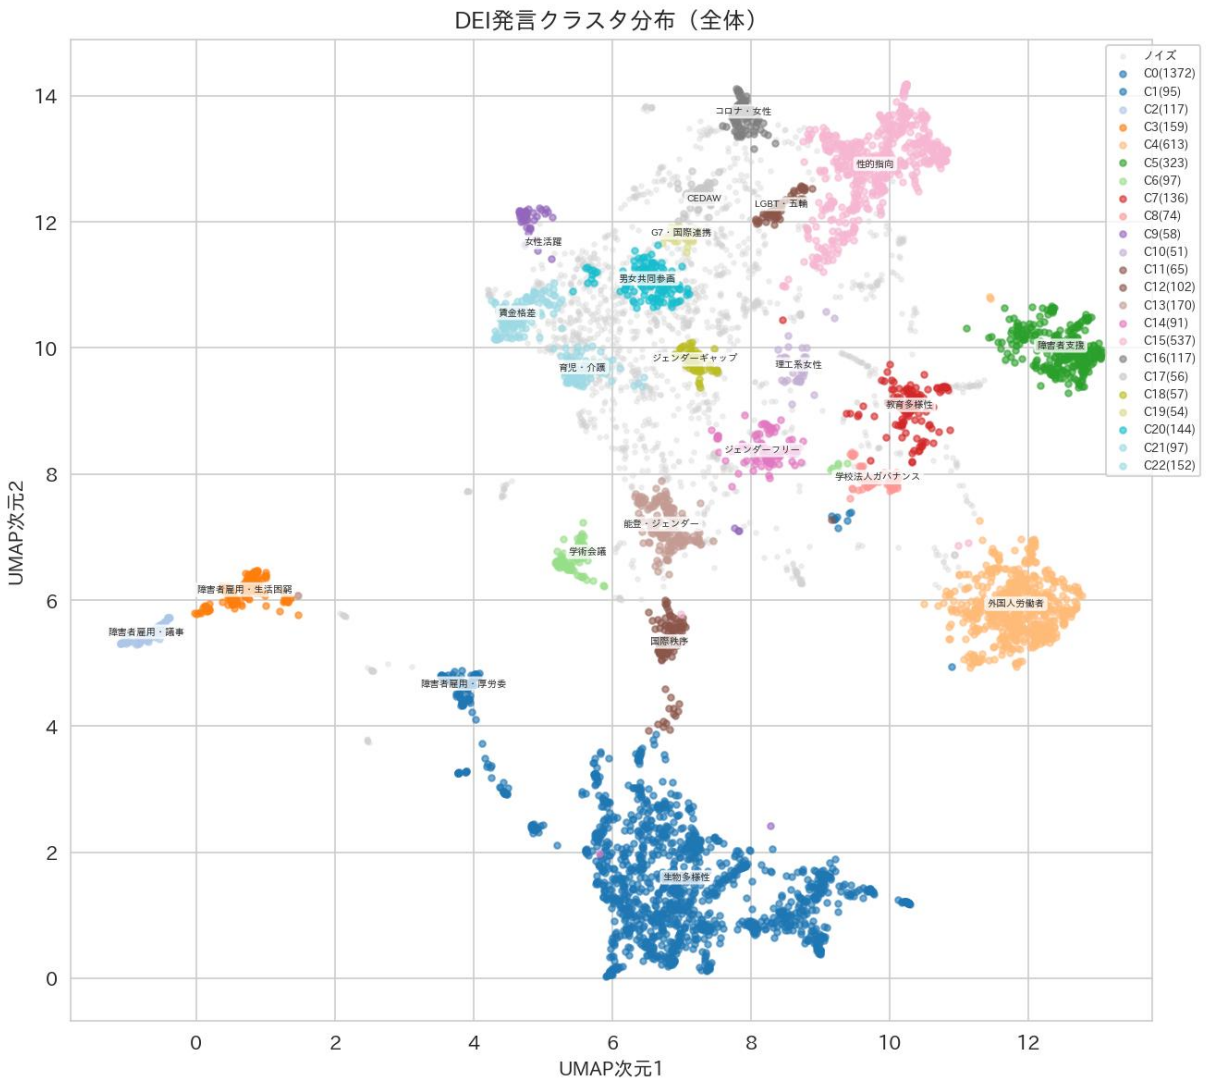
候補	採用	理由
国会議事録	✅	**国民の代表**・バイアス低
パブリックコメント	✕	件数少・テーマ限定
政府統計	✕	数値、事実を収集したもの
SNS等	✕	ノイズ多・匿名・信頼性低

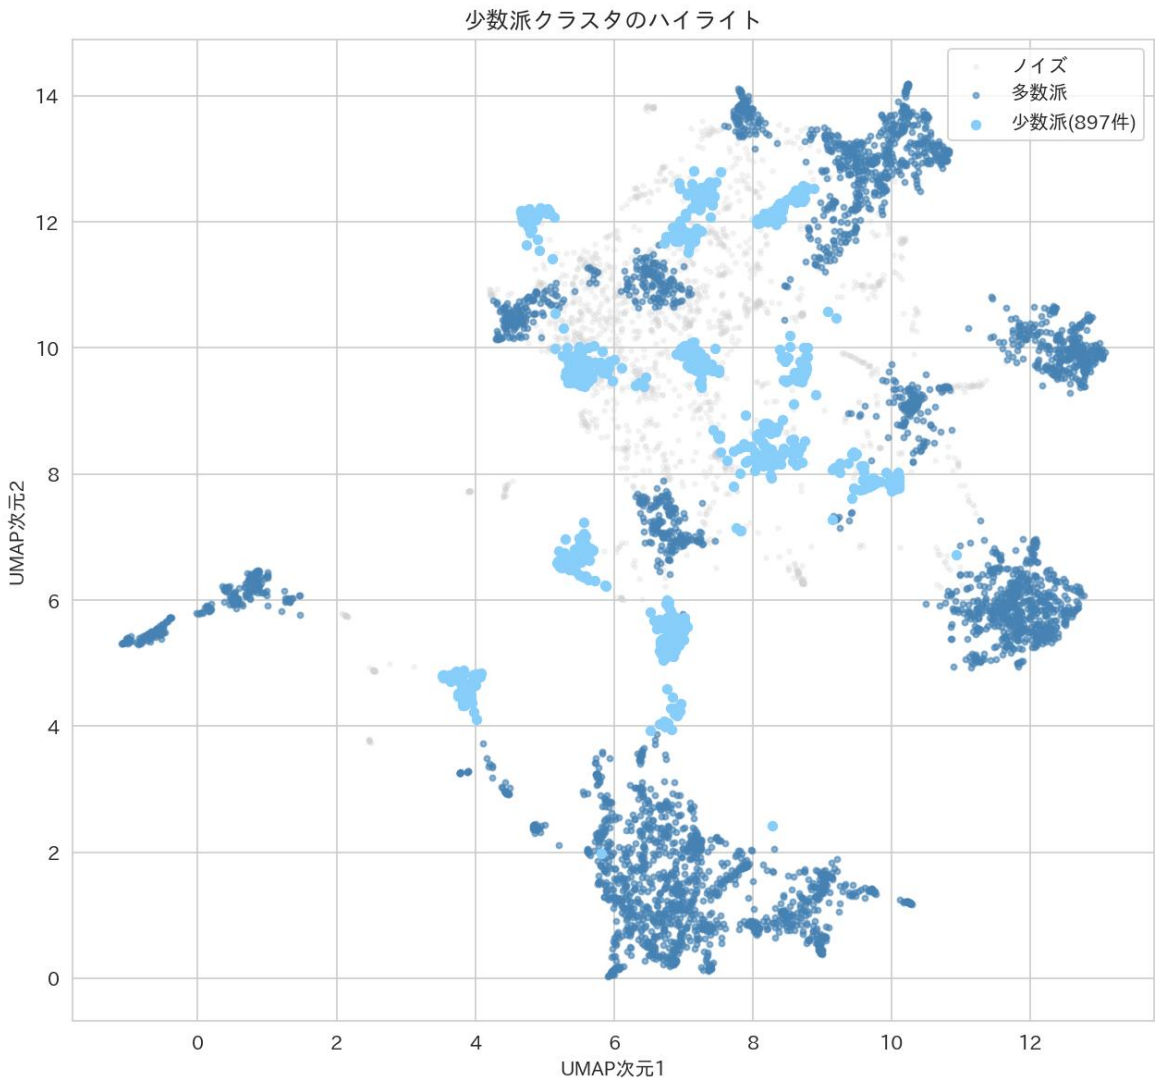
【取得理由の補足】
1.発言者名・会派・日付・会議名も同時取得可能。
2.テキストデータとして構造化済み。
3.分析の切り口が豊富。



除外(頻出の汎用語)
※ DEI文脈外の発言で部分一致するため

判定結果





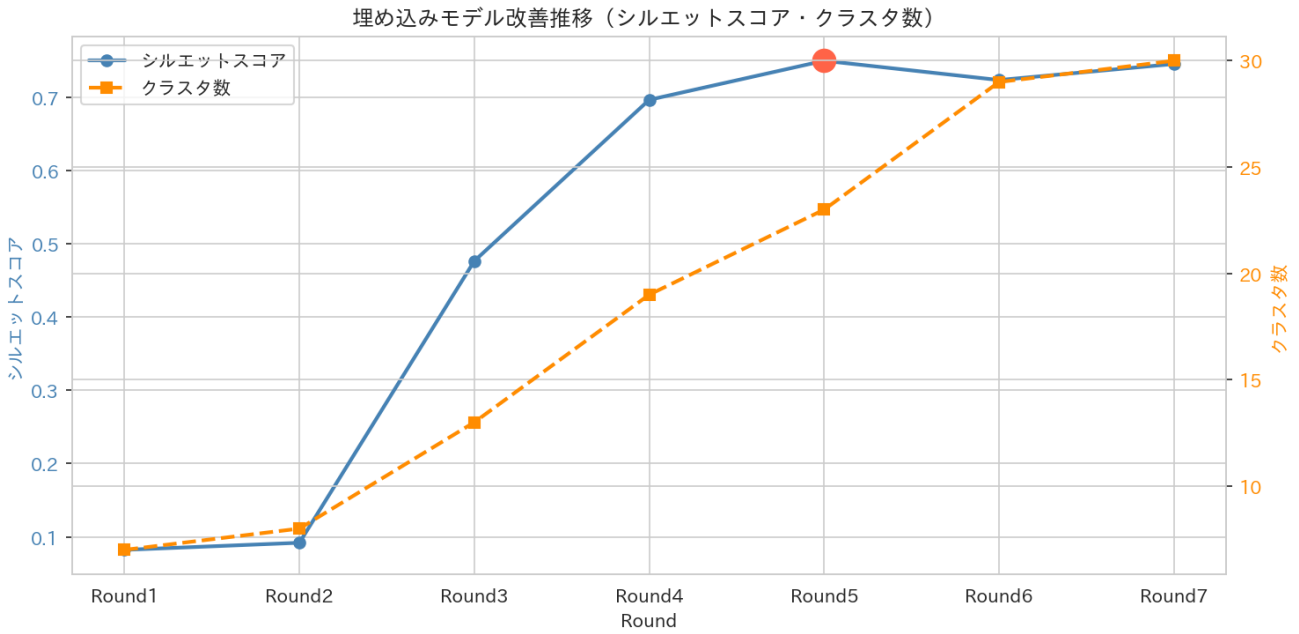
- 23クラスタに自動分類(ノイズ：1,564件・24.8%＝どのクラスタにも属さない意見・強制分類しない設計の証左)
- 少数派12クラスタ・多数派11クラスタ(中央値102件を基準に均等分類)
- 少数派に理工系女性・LGBT・CEDAW・G7など**法的義務のない**専門的DEIトピックが集中→**政策化の遅れ**

精度分析

Round	モデル	手法	スコア
1	MiniLM-L12-v2	K-means	0.0823
2	mpnet-base-v2	K-means	0.0920
3	BERT日本語	HDBSCAN	0.4765
4	multilingual-e5-large	HDBSCAN	0.6965
5	**multilingual-e5-large-instruct**	**HDBSCAN**	**0.7498**
6	Qwen3-Embedding-0.6B	HDBSCAN	0.7235
7	アンサンブルモデル(R5＋R6)	HDBSCAN	0.7454

スコア	評価
0.70以上	Strong(強い)
0.50～0.70	Reasonable(妥当)
0.25～0.50	Week(弱い)
0.25以下	No Structure

シルエットスコア(表のスコア)：-1～1の範囲で、1に近いほどクラスタリングの品質が高い。
出展：シルエット(クラスタリング)

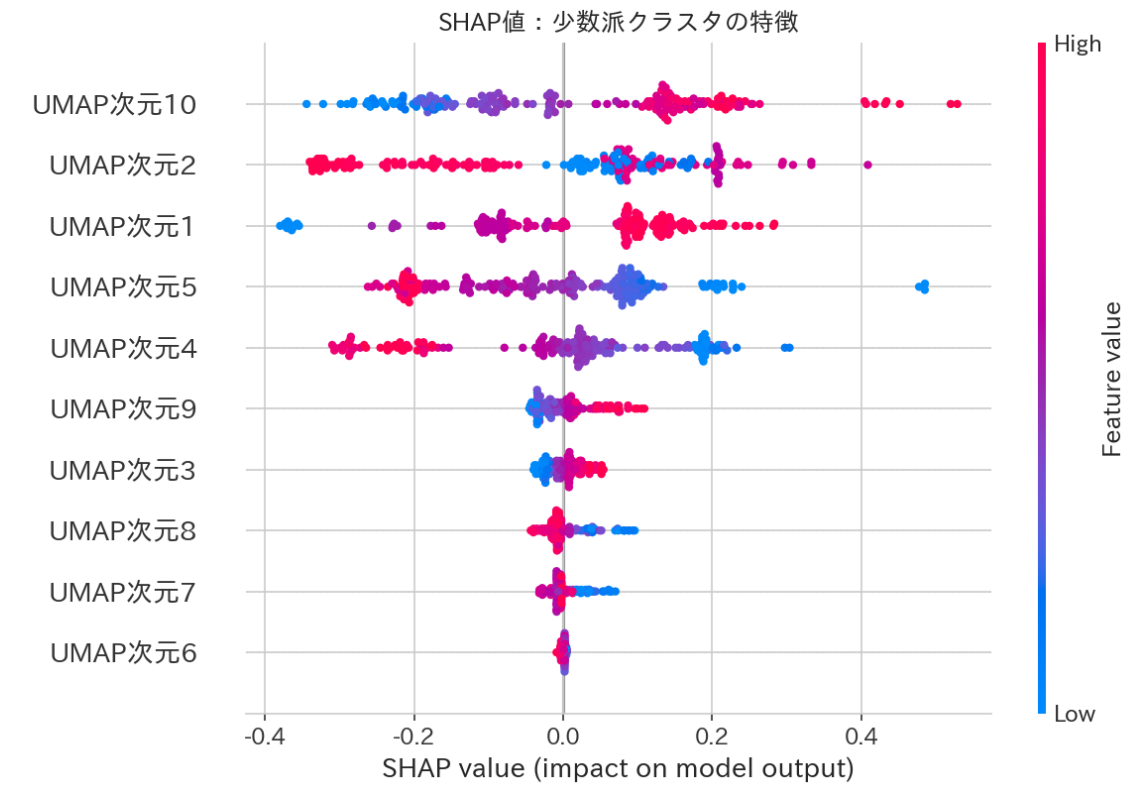


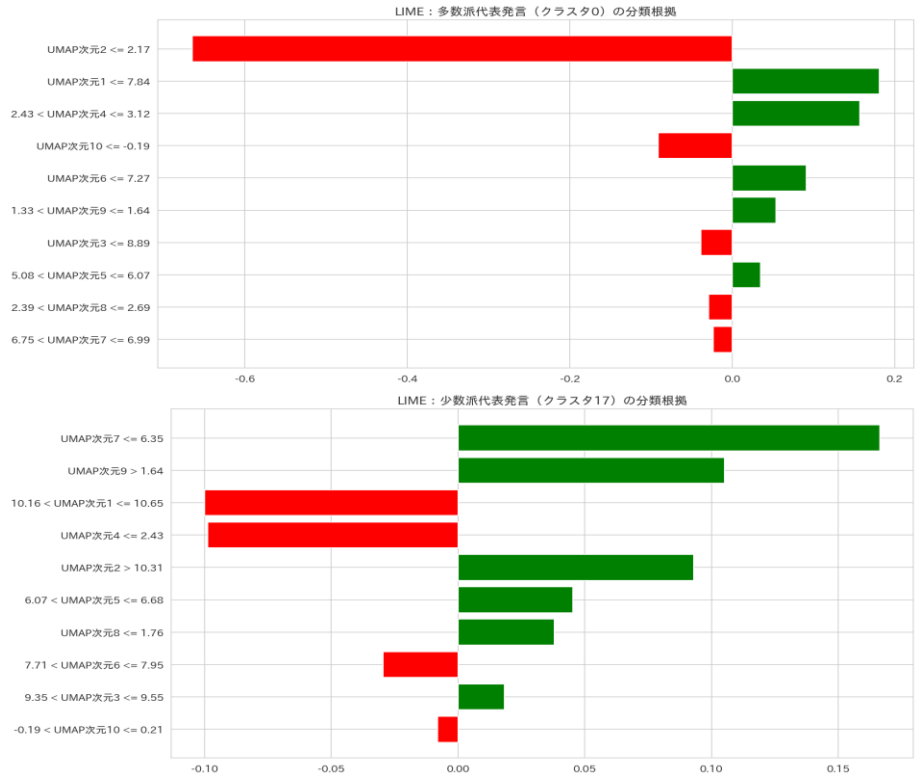
～採用モデル～

- シルエットスコア：0.7498(Strong基準超え)
- クラスタ数：23(ノイズ：1,564件・24.8%)
- SVM*精度：94.45%(少数派/多数派で2値分類)

＊SVM(サポートベクターマシン)：マージン最大化により2クラスのデータを高精度に分類する教師あり学習アルゴリズム

精度に関する考察





- クラスタリング手法(k-means→HDBSCAN)と埋め込みモデルの両方が精度に大きく影響
- モデル精度の向上に伴いDEI意見のより細かな分類を可能にしていることを示唆(クラスタ数7→23)
- 新世代モデル(Round6)、アンサンブルモデル(Round7)でもスコア約0.75のRound5を超えられなかった
  ⇒Round5のDEI発言への特化性が本データに最適、アンサンブルは次元拡張(2048次元)によりUMAPの精度が低下
- UMAP次元10が最重要次元で制度的ガバナンス(少数派)と生物多様性(多数派)を空間的に分離【左図】
  ⇒DEIにおける2つの異なるトピックをモデルが明確に分離し正確に捉えている
- 多数派は単一次元で説明できる単純構造・少数派は複数次元が複合的に絡む複雑な構造【右図】
  ⇒少数派意見は多面的・専門的であることを示唆しクラスタリング精度に寄与している可能性

政府/企業への提言

今回の分析から導いた提言

政府

- DEI政策を「多様性」という曖昧な言葉ではなくD・E・Iそれぞれの指標で議論する
- 少数派クラスタに集中する義務化されていないDEI領域(LGBT・ジェンダーギャップ)も優先的に政策化する
- CEADAW選択議定書の批准など国際基準への対応を政策KPIとして数値化・公表する

【所感】
今回の分析が示した少数派の声が政策にバランスよく届くとき、それは自治体主導の産学官連携による地方創生の新たな出発点となり得るのではないだろうか。
参考：一般社団法人WE-Next

企業

- 「多様性推進」という言葉だけでなく具体的な数値目標で評価すべきでは
- 少数派クラスタのトピック(LGBTやハラスメント)は声を上げにくい領域なので匿名での意見収集システムの整備
- DEIの義務化領域(障害者雇用等)だけではなく義務のない領域にも自主的に取り組む

【所感】
DEIはコストではなくイノベーションの源泉だと考える。ただし、数値目標の達成自体が目的化し”逆差別”を招くことなく、少数派の声も拾い上げる仕組みづくりこそが、真の競争優位につながるのではないだろうか。

工夫点

事例1

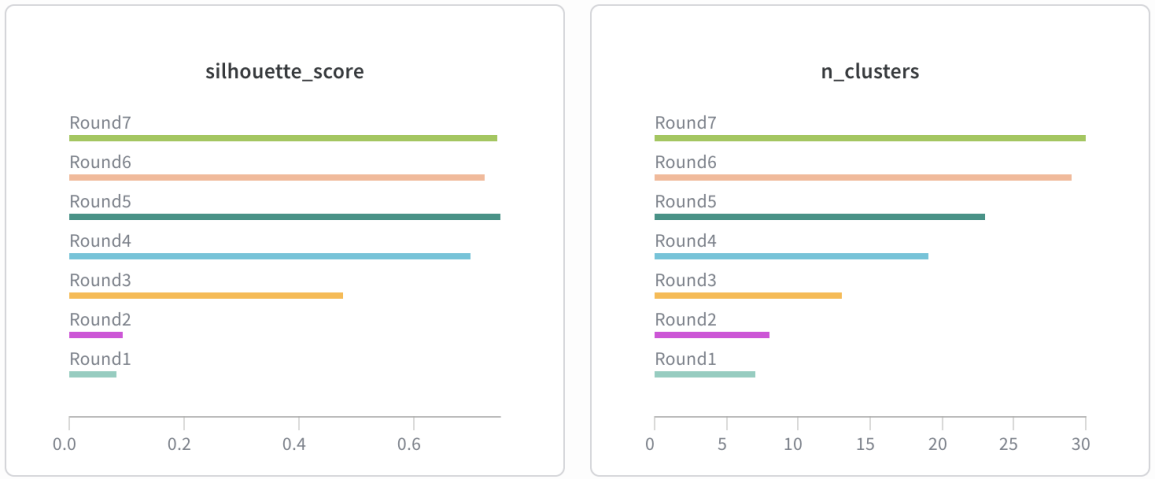
【外部ツールを活用したプロジェクトおよび実験管理】

➢ Notion

※分析途中

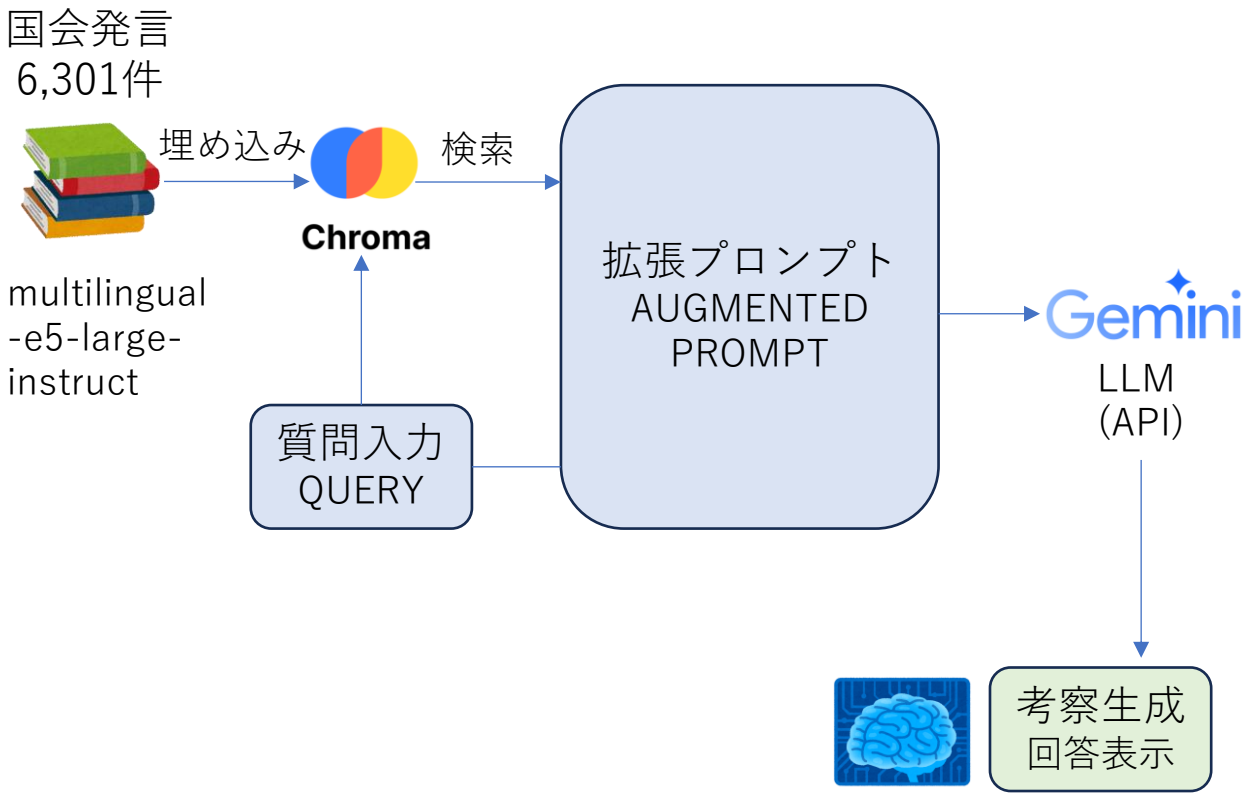


➢ Weights & Biases



事例2

【RAGアプリ化による対話型環境の構築】



◆ StreamlitでUI/UXを設計

◆ Hugging Face SpacesにデプロイしURLで公開

※すべてゼロコストで運用

悩んだこと

少数派の定義
200以下→多すぎ→中央値(102件)で12対11に落ち着いた

公平・包括の除外
EDAで文脈外混入を確認→恣意的判断だが根拠ありと判断し除外

国会議事録の妥当性
議員≠国民だと思うが他データソースよりも信頼性が高いと判断

環境の限界への葛藤
高精度モデルを試みたがVRAM不足・クラッシュで断念→動作可能範囲で最高精度を追求

アンサンブルの誤算
異なるモデルを組み合わせれば精度が上がると仮説を立て実験したが単一モデルを下回る

トピックの命名
代表発言から人間が解釈しトピック名をつける作業で客観性の担保

RAGの技術選定
LLM・ベクトルDB・フレームワーク・デプロイ先など各コンポーネントの最適解に悩んだ

様々悩んだ結果：
悩んだこと自体が技術の糧となり、自分でどう納得し説明できる判断をしたのか、
悩み考えて取り組んだからこそ、自分が作った成果物に対する責任を持とうと決心。

Appendix.

【イラストソース】

◆Freepik｜オールインワンAIクリエイティブスイート：https://jp.freepik.com

◆いらすとや – かわいいフリー素材集：https://www.irasutoya.com

【RAGアプリケーション】

DEI国民の声マップ：https://huggingface.co/spaces/t-okada/dei-voice-map

